UNIVERSIDAD TORCUATO DI TELLA

Departamento de Matemática y Ciencias • Métodos Computacionales (S2 2026)

Reconstrucción y Regularización en Imágenes Tomográficas

De la física de rayos X al álgebra lineal numérica: problemas inversos, optimización cuadrática y balance de regularización

1. Álgebra Lineal & Unicidad

Discretización b = Ax
Rango columna y Teorema de Nulidad
Espacio nulo y 'fantasmas invisibles' SVD

2. Ruido & Métodos Iterativos

Incompatibilidad y Proyección Ortogonal
Gradiente Descendiente vs. Newton
Cota crítica de estabilidad alpha < 2/mu_max

3. Regularización & Escala

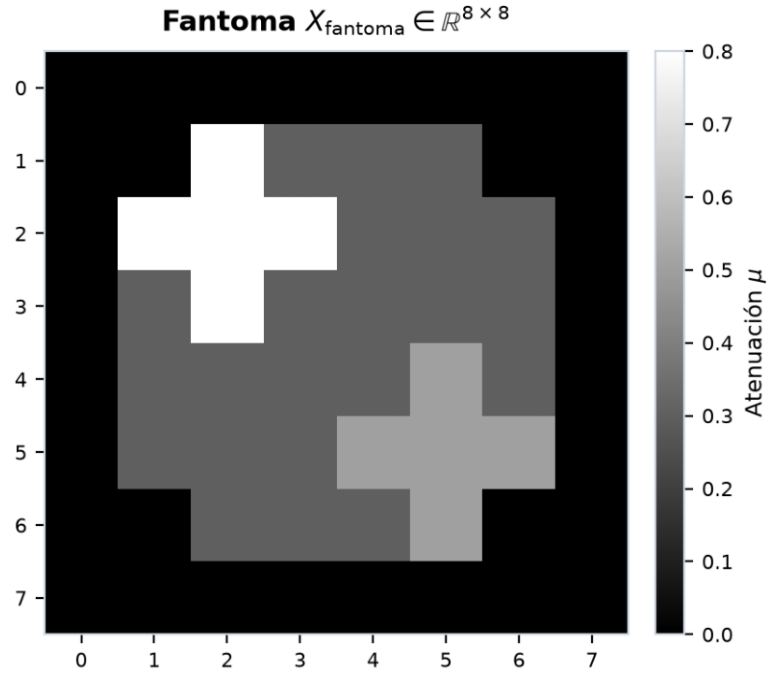
Penalización de suavidad Tikhonov (D)
Compromiso sesgo-varianza (lambda)
Principio de Morozov y Matrices Dispersas

1. De la Física de Rayos X al Sistema Lineal $b = Ax$

Ley de Beer-Lambert y Discretización

- **Modelo Físico:** La intensidad detectada decae exponencialmente según la atenuación acumulada: $I = I_0 \exp\left(-\int_\ell \mu(r)dr\right)$.
- **Linealización:** Al aplicar logaritmo, cada detector entrega una integral lineal de la atenuación del objeto: $-\ln(I/I_0) = \int_\ell \mu(r)dr$.
- **Discretización de la Imagen:** La sección se divide en $n \times n$ píxeles. La matriz $X \in \mathbb{R}^{n \times n}$ se vectoriza por filas en $x \in \mathbb{R}^{n^2}$:
  Posición vector: $k = i \cdot n + j$ $(k = 8i + j$ para $8 \times 8)$.
- **Sistema Matricial:** Cada rayo r suma los píxeles atravesados: $b_r = \sum_j a_{rj} x_j \Rightarrow \mathbf{b = Ax}$ $(A \in \mathbb{R}^{m \times 64}, x \in \mathbb{R}^{64}, b \in \mathbb{R}^m)$.
- **Problema Inverso:** Conocemos A (geometría de rayos) y b (sensores). El objetivo es deducir la variable oculta x (el interior del paciente).

El Fantoma de Prueba (8x8 píxeles)



Valores de μ: 0.8 (alta densidad, hueso/corteza), 0.3 a 0.5 (tejido blando), 0.0 (fondo libre).

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

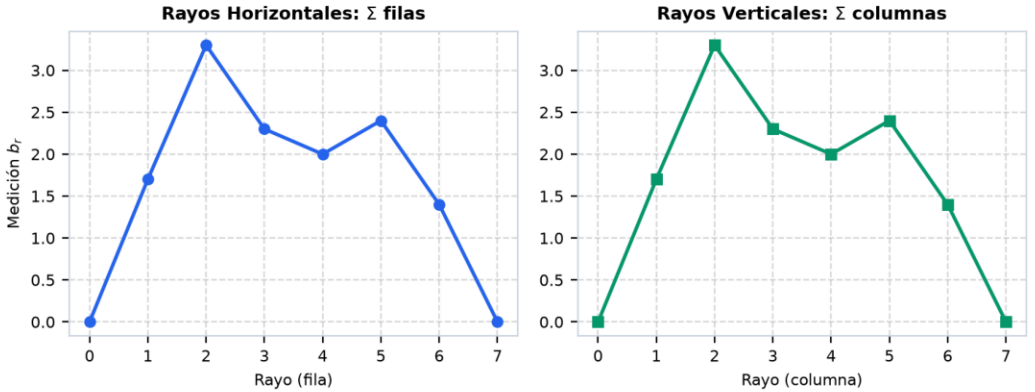
La tomografía es un problema inverso: no podemos mirar x directamente. Disparamos rayos desde afuera y a partir de las sumas b intentamos despejar la foto interior.

2. Geometría de Rayos, Proyecciones y Sinograma

Parametrización y Familias de Rayos

- **Parametrización Continua :** Recta normal al haz perpendicular a n_θ: $u\cos\theta + v\sin\theta = s \quad (\theta \in [0, \pi),\ s = \text{posición detector})$.
- **Modelo Discreto Binario :** El rayo selecciona los centros (i, j) tales que: $\alpha i + \beta j = s$.
  Cada fila a_r^T de A tiene 1s en píxeles cruzados y 0s en el resto.
- **El Sinograma $S \in \mathbb{R}^{K \times q}$:**
  Reúne todas las mediciones ordenadas: cada fila es un ángulo θ_k y cada columna es un detector s_j. Al apilarlo por filas se forma el vector $b \in \mathbb{R}^{Kq}$.
- **Ambigüedad de un solo rayo :** Dos rayos distintos pueden medir la misma atenuación total sumando píxeles diferentes. Para resolver la imagen se requiere combinar múltiples orientaciones angulares.

Verificación: Señales 1D de Filas y Columnas (A2)



Verificación numérica: Las primeras 8 filas de A_2 suman exactamente las filas de X; las 8 siguientes suman las columnas de X. Coinciden con $X.\text{sum}(\text{axis} = 1)$ y $X.\text{sum}(\text{axis} = 0)$.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

Cada ángulo de rayos genera una 'sombra' 1D del objeto. El sinograma es la colección de todas esas sombras. La matriz A contiene la máscara estirada de cada rayo.

3. ¿Cuándo la Reconstrucción es Única? Teorema Rango-Nulidad

Condición Matemática de Unicidad

- **Ecuación del Sistema:** $Ax = b$, con $A \in \mathbb{R}^{m \times 64}$ y $x \in \mathbb{R}^{64}$.
- **Espacio Nulo** $\text{Nul}(A)$**:** Conjunto de vectores tales que $Av = 0$.
  Si existe $v \neq 0$ en el núcleo, entonces:
  $A(x + v) = Ax + Av = b + 0 = b$.
  $\Rightarrow$ Las imágenes x y $x + v$ producen exactamente las mismas mediciones.
- **Teorema de Rango y Nulidad:**
  $\text{rango}(A) + \dim(\text{Nul}(A)) = n^2 = 64$.
- **Condición de Unicidad:** $\dim(\text{Nul}(A)) = 0 \Leftrightarrow$ **rango**$(A) = 64$.
  Se requiere rango columna completo. Esto exige como mínimo $m \geq 64$ rayos.

Comparación de Configuraciones de Adquisición

Configuración	Dimensiones	Rango	Nulidad	Única?
A2 (H, V: 2 dir.)	16 x 64	**15**	49	**NO**
A4 (H, V, Diag: 4 dir.)	46 x 64	**39**	25	**NO**
A7 (+Oblicuas: 7 dir.)	119 x 64	**64**	0	**SÍ**

Mediciones Redundantes:
- A_2: 16 filas vs. rango 15 $\Rightarrow$ 1 medición linealmente dependiente.
- A_4: 46 filas vs. rango 39 $\Rightarrow$ 7 mediciones redundantes.
- A_7: 119 filas vs. rango 64 $\Rightarrow$ 55 mediciones redundantes.

Conclusión: Más rayos no implican directamente unicidad. Solo cuando incorporamos ángulos oblicuos (A_7) cubrimos todas las direcciones necesarias.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

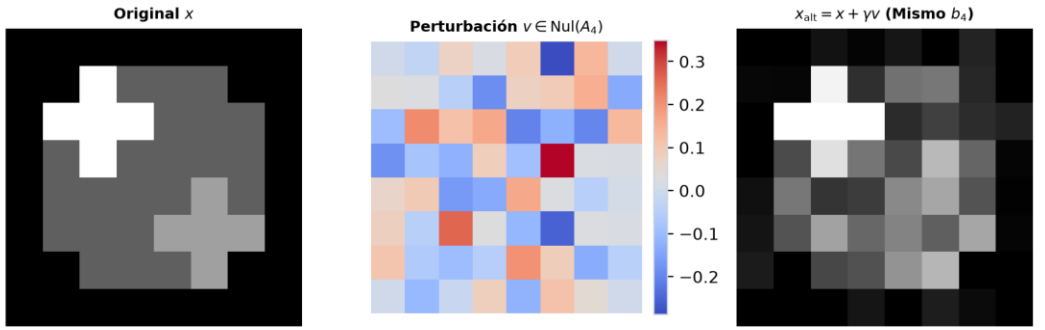
Para que la reconstrucción sea única, el espacio nulo debe ser cero (rango columna completo = 64). Si hay espacio nulo, hay infinitas imágenes distintas que dan la misma medición.

4. Lo Invisible para el Tomógrafo: Vectores Nulos y SVD

SVD y Extracción de Modos Nulos

- **Descomposición SVD:** $A_4 = U\Sigma V^T$.
  Como rango$(A_4) = 39 < 64$, existen exactamente $64 - 39 = 25$ valores singulares nulos ($\sigma_j = 0$ para $j > 39$).
- **Base del Núcleo:** Las columnas de V (filas de V^T) asociadas a $\sigma_j = 0$ forman una base ortonormal de Nul(A_4). En NumPy: $v = V^T[-1]$.
- **Verificación Numérica:** $\|A_4 v\|_2 \approx 9.46 \times 10^{-16} \approx 0$.
- **La Trampa Visual:** Construimos la imagen alterada:
  $x_{\text{alt}} = x_{\text{fantoma}} + \gamma v \quad (\text{con } \gamma = 0.8)$.
  Al escanear: $A_4 x_{\text{alt}} = A_4 x + \gamma A_4 v = b_4 + 0 = b_4$.
  Diferencia en mediciones: $\|A_4 x_{\text{alt}} - b_4\| \approx 1.56 \times 10^{-15}$.

Demostración Visual del 'Modo Fantasma'



¿Por qué A_4 no lo ve?: El vector v tiene alternancia de signos (+ y -) que se cancelan exactamente a lo largo de cada fila, columna y diagonal a 45°. El tomógrafo A_4 es ciego a esas oscilaciones finas de alta frecuencia.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

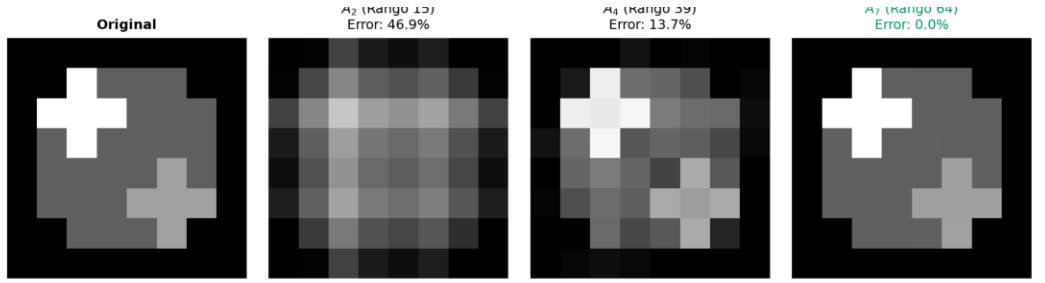
El vector v es una imagen que suma cero en todos los rayos de A4. Sumárselo a la imagen original cambia lo que vemos nosotros, pero para el tomógrafo es exactamente idéntica.

5. Reconstrucción Ideal y Solución de Norma Mínima (`lstsq`)

¿Por qué Residuo Cero NO Implica Buena Imagen?

- **Mediciones Ideales:** $b_k = A_k x_{\text{fantoma}}$ (sin ruido).
  Resolvemos con `np.linalg.lstsq(A_k, b_k)`.
- **Solución de Norma Mínima:** Cuando hay infinitas soluciones, `lstsq` elige la única solución que minimiza la norma euclídea: $\hat{x}_k = \arg\min \|x\|_2$.
- **Proyección sobre el Espacio Fila:**
  Toda imagen se descompone como $x = x_{\text{fila}} + x_{\text{nulo}}$, con $x_{\text{nulo}} \in \text{Nul}(A_k)$.
  `lstsq` descarta por completo la componente x_{nulo} (la hace 0).
- **Resultados Numéricos:**
  A_2: Residuo $= 3.97 \times 10^{-15} \approx 0$, Error Relativo $=$ **46.89%**.
  A_4: Residuo $= 1.59 \times 10^{-14} \approx 0$, Error Relativo $=$ **13.65%**.
  A_7: Residuo $= 1.30 \times 10^{-14} \approx 0$, Error Relativo $=$ **0.00%**.

Comparativa Visual de Reconstrucciones



En A_2 y A_4 la reconstrucción se ve borrosa y lavada porque `lstsq` eliminó la porción de la imagen que vivía en el espacio nulo. Solo en A_7 ($\text{Nul} = \{0\}$) se recupera la totalidad de la información original.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

El residuo mide si la solución coincide con los rayos del escáner, no con la imagen real. Un residuo cero con espacio nulo descarta los detalles invisibles y produce una imagen lavada.

6. Adquisición Real con Ruido e Incompatibilidad del Sistema

Impacto del Ruido Gaussiano en Detectores

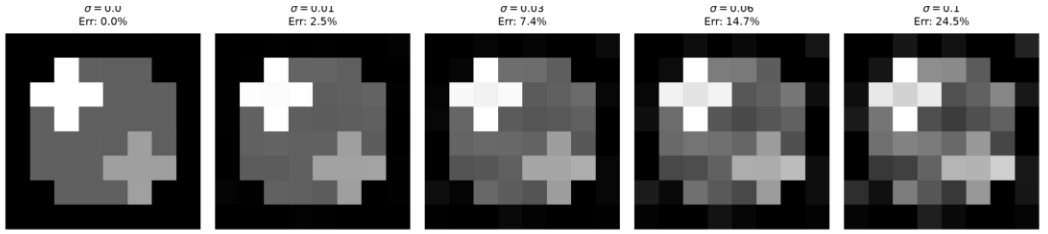
- **Modelo Perturbado :** $b_\sigma = b_7 + \eta_\sigma$, con $\eta_\sigma = \sigma \cdot \text{escala} \cdot z$.
  $z \sim \mathcal{N}(0, 1)$ es un vector único; $\sigma \in \{0, 0.01, 0.03, 0.06, 0.10\}$.

- **Incompatibilidad del Sistema :**
  El vector de mediciones limpias b_7 pertenece a $\text{Col}(A_7) \subset \mathbb{R}^{119}$ (dimensión 64). El ruido η_σ saca a b_σ fuera del subespacio. Como $119 > 64$, no existe ningún x capaz de satisfacer las 119 ecuaciones ruidosas simultáneamente.

- **Mínimos Cuadrados :** Buscamos $\hat{x}_\sigma$ que minimice la distancia euclídea:
  $\hat{x}_\sigma = \arg\min \|A_7 x - b_\sigma\|_2^2$.

- **Por qué aparecen valores negativos :** La atenuación real es $\mu \geq 0$.
  `lstsq` no tiene restricciones físicas; para compensar el ruido y acercar las sumas a b_σ, fuerza a píxeles del fondo a tomar valores negativos (hasta -0.13).

Evolución Visual del Error con el Ruido



Tendencias Cuantitativas :
- El error relativo crece linealmente con σ (de 0% a 24.5%).
- El residuo deja de ser nulo (pasa de 10^{-14} a 0.9070) porque mide la distancia ortogonal mínima desde b_σ hasta el plano $\text{Col}(A_7)$.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

El ruido hace que las 119 ecuaciones se contradigan entre sí. Mínimos cuadrados encuentra el punto más cercano, pero deja un residuo inevitable y genera valores negativos por falta de restriccione

7. La Reconstrucción como Proyección Ortogonal en $\mathbb{R}^{119}$

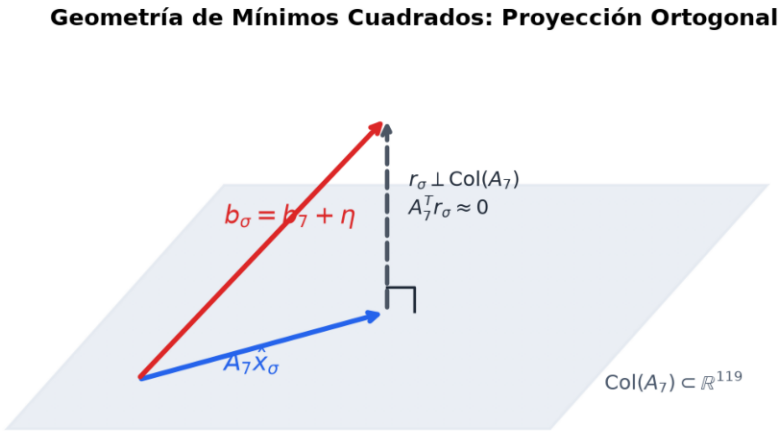
Ortogonalidad del Residuo y Ecuaciones Normales

- **Comprobación Numérica ($\sigma = 0.06$):**
  $\|A_7^T r_\sigma\|_2 = \|A_7^T(b_\sigma - A_7\hat{x}_\sigma)\|_2 \approx \mathbf{3.33 \times 10^{-14} \approx 0}$.

- **Interpretación Geométrica:**
  $A_7^T r_\sigma$ es el producto escalar de r_σ contra cada una de las 64 columnas de A_7.
  Como da cero contra todas, el residuo es ortogonal a cada columna $\Rightarrow r_\sigma \perp \text{Col}(A_7)$.
  Por definición, el punto del subespacio cuya distancia a b_σ cae a 90° es
  la **proyección ortogonal**: $\text{Proy}_{\text{Col}(A_7)}(b_\sigma) = A_7\hat{x}_\sigma$.

- **Ecuaciones Normales:**
  $A_7^T(b_\sigma - A_7\hat{x}_\sigma) = 0 \Leftrightarrow \mathbf{A_7^T A_7 \hat{x}_\sigma = A_7^T b_\sigma}$.

Distinción Crucial: Dos Conceptos de 'Proyección'



1. **Proyección Tomográfica (Física):** El escáner proyecta la atenuación de una sección 2D sobre una línea 1D de detectores para cada ángulo ($x \mapsto Ax$).
2. **Proyección Ortogonal (Matemática):** Mapeo en $\mathbb{R}^{119}$ que baja el dato ruidoso b_σ perpendicularmente sobre $\text{Col}(A_7)$ para encontrar la mejor aproximación.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

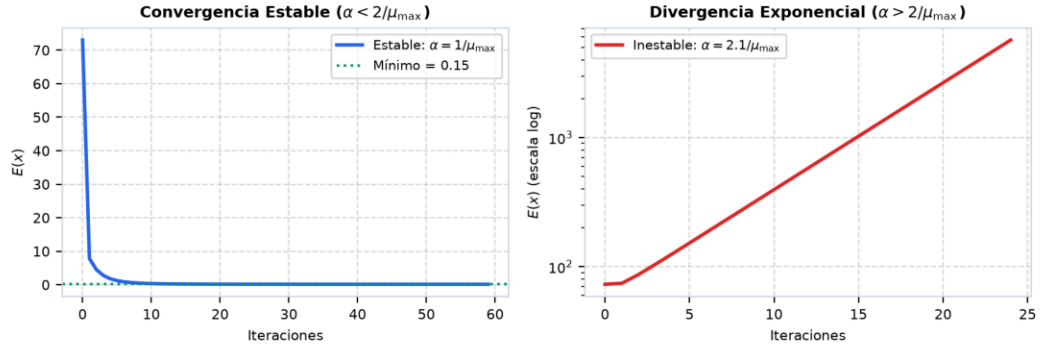
Hacer A7.T @ residuo calcula el producto escalar contra las columnas. Como da 0, el residuo forma 90 grados con el espacio de mediciones y A7 @ x_hat es la sombra perpendicular exacta.

8. Métodos Iterativos: Gradiente Descendiente y Tasa Crítica

Función de Costo y Análisis de Convergencia

- **Función Objetivo :** $E(x) = \frac{1}{2}\|A_7 x - b_\sigma\|^2$ (parábola en $\mathbb{R}^{64}$).
- **Gradiente y Hessiana :**
  $\nabla E(x) = A_7^T(A_7 x - b_\sigma)$ (apunta al máximo crecimiento).
  $H = \nabla^2 E(x) = A_7^T A_7$ (simétrica, constante y definida positiva).
- **Algoritmo Gradiente Descendiente :**
  $x_0 = \mathbf{0}, \qquad x_{t+1} = x_t - \alpha \nabla E(x_t)$.
- **Cota Crítica de Estabilidad :** El mayor autovalor de H es $\mu_{\max} \approx 47.6$.
  La contracción del error exige: $|1 - \alpha\mu_{\max}| < 1 \Leftrightarrow \mathbf{0 < \alpha < \frac{2}{\mu_{\max}}} \approx 0.042$.
  - Si $\alpha < 2/\mu_{\max}$: el costo desciende de forma estable al mínimo.
  - Si $\alpha > 2/\mu_{\max}$: el paso se pasa de largo del valle y **diverge exponencialmente**.

Convergencia Estable vs. Explosión Numérica



Que las curvas se aplanen indica que el algoritmo alcanzó el fondo del cuenco donde el gradiente vale cero ($\|\nabla E(x)\| \approx 0$). Cuando $\alpha > 2/\mu_{\max}$, el costo salta hacia las paredes externas del valle cuadrático y explota hacia infinito.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

mu_max mide la pendiente más empinada del cuenco. Si el paso alfa es mayor a 2/mu_max, el algoritmo rebota de pared en pared y diverge. Por debajo de esa cota, siempre converge.

9. Método de Newton y Comparación de Métodos de Inversión

¿Por qué Newton Resuelve en 1 Sola Iteración?

- **Paso de Newton:** Resuelve $Hp_t = \nabla E(x_t)$ mediante `solve(H, g)` y actualiza: $x_{t+1} = x_t - p_t$.

- **Convergencia en 1 Paso:**
  Newton aproxima la función por su polinomio de Taylor cuadrático:
  $E(x_t + p) \approx E(x_t) + \nabla E(x_t)^T p + \frac{1}{2} p^T H p$.
  Como $E(x) = \frac{1}{2}\|A_7 x - b_\sigma\|^2$ **ya es una parábola exacta**, la aproximación coincide al 100% con la función real. Al igualar el gradiente del modelo a cero, salta directamente al mínimo en la primera iteración desde cualquier punto:
  $x_1 = x_0 - H^{-1}\nabla E(x_0) = (A_7^T A_7)^{-1} A_7^T b_\sigma = \hat{x}_{\text{ls}}$.

- La diferencia numérica entre la iteración 1 y 2 es de orden 10^{-14}.

Comparación Integral de Algoritmos

Método	Tipo	Iteraciones	Costo / Paso
np.linalg.lstsq	Directo (SVD)	**1 paso**	O(n^3) factoriz.
Método de Newton	2do orden	**1 paso**	O(n^3) solve H
Gradiente Desc.	1er orden	**~150 pasos**	O(m n) matriz-vec

¿Cuál es mejor para tomografía real?:
- En 8×8, Newton y `lstsq` son instantáneos.
- En 128×128 ($n^2 = 16.384$), armar H de 16.384×16.384 requiere 2 GB de memoria y resolver $Hp = g$ cuesta billones de operaciones.
- **Gradiente Descendiente** es el único escalable porque solo requiere multiplicar matrices dispersas Ax y $A^T r$ sin almacenar nunca H.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

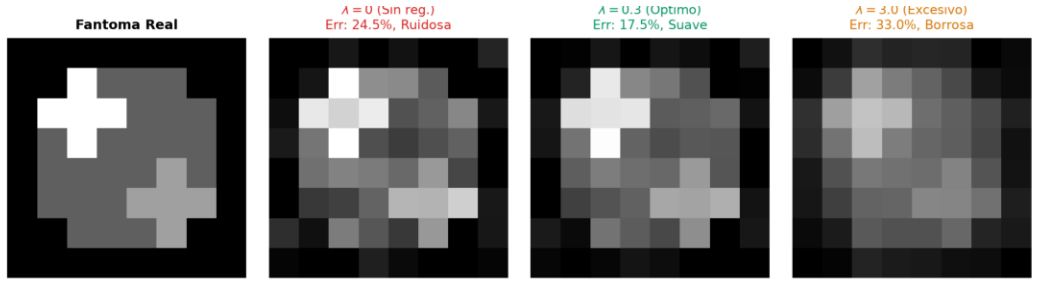
Newton resuelve en 1 paso porque la función ya es una parábola cuadrática exacta. Pero no escala a imágenes grandes porque invertir H cuesta O(n^3). Por eso en tomografía real se usa Gradiente.

10. Regularización Cuadrática: Prior de Suavidad y Trade-Off

El Operador de Diferencias y el Costo Regularizado

- **Motivación:** Mínimos cuadrados con ruido produce imágenes con granulado y saltos bruscos entre píxeles adyacentes. Incorporamos un prior de suavidad.
- **Matriz de Diferencias** $D = \binom{D_h}{D_v} \in \mathbb{R}^{112 \times 64}$**:**
  D_h calcula diferencias horizontales $X_{i,j+1} - X_{i,j}$ (-1 en k, +1 en $k+1$).
  D_v calcula diferencias verticales $X_{i+1,j} - X_{i,j}$ (-1 en k, +1 en $k+n$).
  $\|Dx\|_2^2$ mide la falta de suavidad / rugosidad. Si la imagen es constante, $Dx = 0$.
- **Función de Costo Regularizada:**
  $J_{\sigma,\lambda}(x) = \frac{1}{2}\|A_7 x - b_\sigma\|^2 + \frac{\lambda}{2}\|Dx\|^2$.
- **Gradiente:** $\nabla J_{\sigma,\lambda}(x) = A_7^T(A_7 x - b_\sigma) + \lambda D^T D x$.

El Compromiso del Hiperparámetro lambda



Impacto de λ:
- $\lambda = 0$ (Sub-regularizado): Ajusta el ruido; artefactos y error alto (24.5%).
- $\lambda = 0.3$ (Óptimo): Elimina el ruido en el fondo y reduce el error a 16.8%.
- $\lambda = 3.0$ (Sobre-regularizado): Suaviza en exceso, difumina bordes anatómicos.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

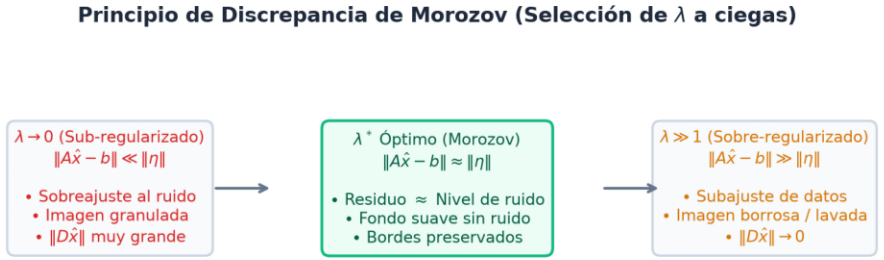
La matriz D mide los saltos entre vecinos. El término lambda * ||Dx||^2 frena las oscilaciones causadas por el ruido. Si lambda es muy chico queda ruido; si es muy grande queda borrosa.

11. Reconstrucción en Alta Resolución y Selección de λ a Ciegas

Desafíos de Escala y Matrices Dispersas

- **Salto de Escala:** Imagen desconocida de 128×128 píxeles. Vector $x \in \mathbb{R}^{16.384}$, matriz $A \in \mathbb{R}^{Kq \times 16.384}$.
- **Estructura Rala (Sparse):** Cada rayo solo atraviesa ≈ 128 píxeles; el 99% de A son ceros. Usar matrices densas colapsaría la memoria. Se opera con `scipy.sparse.csr_matrix` y productos encadenados: $\nabla J_\lambda(x) = A^T(Ax - b) + \lambda D^T(Dx)$.
- **Principio de Discrepancia de Morozov:** ¿Cómo elegimos λ si la imagen original permanece oculta? Sabemos que las mediciones reales cumplen $b = Ax_{\text{real}} + \eta$. $\Rightarrow$ La reconstrucción óptima no debe forzar residuo 0, sino hacer que: $\|\mathbf{A\hat{x}_\lambda - b}\|_2 \approx \|\boldsymbol{\eta}\|_2$ (estimación de ruido).

Criterio de Selección de Hiperparámetros



Regla Práctica de Morozov:

- Si $\|A\hat{x} - b\| \ll \|\eta\| \Rightarrow \lambda$ es chico: estamos ajustando ruido.
- Si $\|A\hat{x} - b\| \gg \|\eta\| \Rightarrow \lambda$ es excesivo: perdimos detalles de la imagen.
- El λ^* ideal iguala el residuo con la cota de ruido físico de los detectores.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

En la vida real no conocemos la imagen original. Elegimos lambda comparando la norma del residuo con la estimación del ruido (Morozov): el residuo debe ser del mismo tamaño que el ruido.

12. Síntesis Conceptual del Proyecto Aplicado

1. Problema Inverso y Modelo Discreto

- La tomografía infiere una causa oculta (distribución de atenuación x) a partir de sus efectos integrados (mediciones de detectores b).
- La discretización b = Ax traduce las leyes físicas continuas a un marco algebraico riguroso.

2. Identificabilidad: Rango y Espacio Nulo

- La geometría de rayos determina la solubilidad única del problema.
- Rango completo (rango=n^2, Nul={0}) es indispensable para no tener patrones invisibles o fantasmas SVD que confundan al tomógrafo.
- La redundancia angular es preferible a la redundancia paralela.

3. Ruido e Incompatibilidad Geométrica

- Los errores de medición sacan a b de Col(A), volviendo el sistema incompatible.
- Mínimos cuadrados resuelve la incompatibilidad mediante una proyección ortogonal exacta en R^m (A^T r = 0).
- Aparecen valores negativos al ser un ajuste sin restricciones físicas.

4. Computación Escalable y Regularización

- GD es el método de elección para alta resolución con matrices ralas, siempre que el paso respete la cota de estabilidad alpha < 2/mu_max.
- Tikhonov resuelve el mal condicionamiento: filtra oscilaciones de ruido y estabiliza la reconstrucción mediante el principio de Morozov.

CLAVE PARA EL COLOQUIO ORAL (PUNCHLINE):

Mensaje final: Para reconstruir tomografías reales se combinan tres pilares: adquisición angular variada (rango), optimización iterativa liviana (GD) y priors de suavidad física (Tikhonov).